

FORGE (Flexible Orchestration of Runtime-Generated Experts)

A “Four-Phase” Automated AI Development System:

Human-Guided Hypothesis로부터 Debate 기반 Hypothesis 선별,
Dynamic Agent 기반 code 개발, 그리고 Ablation research까지

성균관대학교 소프트웨어학과, 고려대학교 데이터과학과
변지환, 황정현

Contents

- 01** Introduction
- 02** Method
- 03** Experiments
- 04** Future Works

Introduction

고민 : 좋은 Co-Scientist란 무엇일까?

상황 :

현존하는 SOTA LLM모델도 복잡한 과학 연구의 전체 파이프라인을 독립적으로 수행하는 데 한계를 가지고 있음.

특히 창의적 가설 설정, 실험 설계의 미묘한 판단, 예상치 못한 결과 해석 등에서 인간의 전문성이 여전히 필요함.

그렇다면?

이름 그대로 “Co-Scientist” !!

실제 모델 개발 과정에서 발생하는 병목 지점들을 효율적으로 해결하고,
인간 연구자의 역량을 증폭시키는 역할에 집중해보자.

Introduction

고민 : 좋은 Co-Scientist란 무엇일까?

Industry 5.0 패러다임 적용: 인간 중심의 Agentic AI 협업 시스템¹

- Industry 5.0는 Agentic AI 기술을 Industry 4.0의 복잡성을 줄이고 인간 중심적(human-centric), 지속가능한(sustainable), 회복력 있는(resilient) 원칙을 강조하는 새로운 산업 패러다임

Romero & Suyama (2025)가 제안한 Agentic AI for intent-Based Industrial Automation 개념을 적용하고자 하였습니다.

- **자연어 기반 Intent 표현:** 연구자가 "전자현미경(SEM) 이미지로부터 깊이를 예측하는 AI 알고리즘 개발"과 같이 고수준의 연구 목표를 자연어로 표현하고, Human-in-the-loop를 통해 Agentic AI와 지속적으로 intent 협의
- **Intent 분해:** AI 시스템이 이를 실행 가능한 구성요소(Expectations, Conditions, Targets, Context, Information)로 분해
- **전문화된 Sub-Agent 협업:** 데이터 분석, 모델 아키텍처 설계, 코드 개발 등 각 영역별 전문 에이전트가 협력하여 작업 수행
- **인간-기계 상호작용 단순화:** 복잡한 기술적 세부사항은 AI가 처리하고, 연구자는 창의적 판단과 전략적 의사결정에 집중

이러한 접근법은 과학 연구에서 인간의 창의성과 직관을 보존하면서도 반복적이고 계산 집약적인 작업을 효율적으로 자동화할 수 있는 진정한 "협업"(Co-Science) 환경을 구현합니다.

¹ Romero, M. L., & Suyama, R. (2025). Agentic AI for intent-based industrial automation. arXiv preprint arXiv:2506.04980.

Introduction

Human-on-the-loop(HOTL) 란?

AI 시스템이 자율적으로 운영되면서도 인간이 감독자로서 예외 상황에만 개입하여
효율성과 안전성의 균형점을 제공하는 인간-컴퓨터 상호작용(Human-Computer Interaction) 설계 방식

Human-in-the-Loop (HITL)² SAMSUNG SDS - insight report
자동화된 결정이 실행되기 전 인간의 검증이 필요한 모델
모든 중요 결정에 인간의 직접적 승인 필요
높은 정확성과 품질 보장, 낮은 처리 속도

Human-on-the-Loop (HOTL)

시스템이 자율적으로 운영되지만 인간 감독 하에 있는 모델로, 이상 징후 발생 시 개입 가능한 방식
일상적 운영은 AI가 담당, 예외상황에만 인간 개입
효율성과 안전성의 균형점

Human-out-of-the-Loop (HOOTL)

사전 정의된 경계 내에서 완전 자율 운영하는 시스템
인간은 목표와 제약조건만 설정, 실행 과정 불개입
최고 효율성, 제한적 적용 영역

2 SAMSUNG SDS - AI 시스템을 강화하는 휴먼인더루프(HUMAN IN THE LOOP) https://www.samsungsds.com/kr/insights/human_in_the_loop.html


Introduction

Ablation Research 란?

핵심 아이디어:
가장 영향력 있는 코드 블록(ML 요소) 찾기

Google Research의 MLE-STAR는 **Ablation Study**를 통해 현재 솔루션에서 어떤 부분이 성능에 가장 큰 영향을 미치는지 분석합니다.

- **목표:** 모델의 여러 구성 요소(예: 피처 엔지니어링, 인코딩 전략 등) 중 어떤 것을 수정했을 때 성능 변화가 가장 큰지 식별합니다.
- **방식:** 특정 ML 파이프라인 구성 요소를 나타내는 코드 블록을 비활성화하거나 수정하여 성능 변화를 체계적으로 평가합니다.
- **결과:** 분석 결과를 바탕으로 가장 개선 효과가 클 것으로 예상되는 코드 블록을 다음 개선 (Refinement) 단계의 타겟으로 설정합니다.



Introduction

Ablation Research 란?

어떻게 가장 중요한 코드 블록을 찾는가?

1. **Ablation Study 스크립트 생성 (Aabl)**
 - 현재 솔루션 코드를 기반으로 특정 구성 요소(2-3개)를 수정하거나 비활성화하는 Python 스크립트를 생성합니다.
 - 이전 연구에서 다루지 않았던 새로운 파이프라인 구성 요소를 탐색하도록 유도합니다.
2. **스크립트 실행 및 결과 요약 (Asummarize)**
 - 생성된 스크립트를 실행하여 각 구성 요소 수정 시 성능 변화를 측정합니다.
 - 실행 결과(로그 포함)를 간결한 요약문으로 정리하여 핵심 정보를 추출합니다.
3. **타겟 코드 블록 추출 (Aextractor)**
 - 요약된 ablation study 결과를 분석하여 성능에 가장 큰 영향을 미친 코드 블록을 식별합니다.
 - 이전에 수정되지 않았던 코드 블록을 우선적으로 타겟팅하여 다양한 탐색을 유도합니다.

왜 Ablation Study가 효과적인가?

- **전략적 탐색:** 전체 코드를 한 번에 수정하는 대신, 가장 중요한 부분에 집중하여 깊이 있는 탐색을 가능하게 합니다. 이는 마치 의사가 전체적인 건강 상태를 살피기보다 특정 증상의 원인을 집중적으로 진단하는 것과 같습니다.
- **지속적인 성능 개선:** 각 개선 단계마다 가장 영향력 있는 요소를 먼저 수정함으로써 초기 단계에서부터 빠르고 큰 성능 향상을 기대할 수 있습니다.
- **다양성 확보:** 이전에 시도했던 ablation study 요약 정보를 다음 단계에 피드백으로 제공하여, 동일한 요소만 반복해서 수정하는 것을 방지하고 파이프라인의 여러 부분을 탐색하도록 유도합니다.


Introduction

01

AI 모델 개발 시,
여러 아이디어 고려

- 선행 연구 리서치 필요
- 여러 시도하고자 하는 가설 존재
- 구현, 실현 가능성 검증
- 가능성이 낮다면 추가 개선 방향 조사.

시간 소모적 작업




Introduction

02

인간의 의도 파악을 위한 Human-on-the-loop 접근법

Agentic AI의 단점 중 자율성을 너무
부여하면 **유저의 intent 반영**을 잘
하지 못하는 문제

이를 위해 Human-on-the-loop
접근법 도입



Google Gemini의 딥 리서치: 유저의 intent를 검증/피드백 받는 단계


Introduction

03

범용적인 Task에 적용 가능한 Agentic AI 시스템

본 대회 3D Metrology 테스트에서만 작동하는 아키텍처 설계는 의미 없음.

주어진 Task에 따라, “Dynamic하게” Agent의 Spec.을 생성하여 유연하게 작동하는 Agent 구조를 설계하였음.



Method: Feature Overview

Overview

CrewAI

CrewAI는 역할 기반의 자율적 Multi-AI 에이전트들을 조직화하는 오픈소스 Python 프레임워크입니다. 협업 지능을 통해 에이전트들이 원활하게 협력하여 복잡한 작업을 수행할 수 있게 합니다.




Exa search tool


Exa는 LLM과 에이전트에 최적화된 AI 검색 엔진으로, API를 통해 원활한 인터넷 접근과 빠르고 정확한 결과를 제공



자체 구현 Terminal tool

CrewAI의 Custom tool 기능을 통해 본 프로젝트만의 자체 터미널 구현 (실행/디버깅 등을 위한 툴)





Method: Pipeline Overview

Phase 1: 프로젝트 시작점

목표

- Project Leader가 시스템 초기화
- 프로젝트 목표, 계획, 평가 기준 정의

출력

- 최우선 초기 가설 (h_0) 생성
- Phase 2로 전달

Phase 2: 리서치 & 가설 생성

Research Agent

- 초기 가설(h_0) 분석
- 웹/논문 리서치 기반 n 개 세부 가설 제안

Debate Agent

- 가설들 간 장단점 논의
- 찬반 토론을 통한 가설 필터링

출력

- 우선순위 지정된 최대 3개 가설 선별

Phase 3: 반복적 개선 사이클

Agent Factory

- 가설 구현을 위한 전문 에이전트 동적 생성

Dynamic Agent Pool

- **Model Agent**: (ex. CNN_Classifier_Agent)
- **Model Agent**: (ex. CycleGAN_Agent)
- **Model Agent**: (ex. Inference_Optimization_Agent)

...

성능 평가

- **Candidate Eval Agent**: 모델 성능 측정
- **Performance Check**: 목표 달성 여부 판단

-  **만족**: Phase 4로 진행
-  **불만족**: 다른 가설로 재시도

Phase 4: 어블레이션 연구

심층 분석

Ablation Agent

- Model Ablation: 구조별 영향 분석
- Data Ablation: 데이터/전처리 영향 분석
- Ensemble Ablation: 모델 조합 효과 분석

Refinement Agent

- 분석 결과 종합
- 핵심 부분 집중 개선

피드백 루프

- 향상된 코드 → Performance Check → 지속적 개선

핵심 특징

- ✨ 최소한의 인간 개입 (Human-on-the-Loop)
-  동적 에이전트 생성 (Task 맞춤형)
-  체계적 성능 개선 (가설 → 구현 → 평가)
-  ChatOps 기반 사용자 친화적 인터페이스

Method: Phase 1

Project Leader

- **User Input**
 - Task 설명 및 지시
 - 목표 성능 제시, e.g. RMSE 3.8 이하
 - Baseline 가설 (max 3)
 - 가설 시도 및 성능 비교 최적값 3개
 - 3개 초과 시 성능 정체⁴
(참조 논문 상에서 최대 3개 가설에 대해서 진행하는 것만 유의미함을 증명)
 - **Project analysis**
 - User input (task 지시, 목표 성능, baseline 가설) 분석
 - 추후 타 agents들이 참고할 Task에 대한 종합적 요약본
 - **Code analysis**
 - (if exists) User가 첨부한 참고 코드 분석
 - 코드 구조, 주요 클래스·함수 분석
- HOTL system executed -----
- (After Phase 2) Dynamic agent planning
 - (After Phase 4) Report generation

4 Trirat, P., Jeong, W., & Hwang, S. J. (2025). AutoML-Agent: A multi-agent LLM framework for full-pipeline AutoML. In Proceedings of the 42nd International Conference on Machine Learning.

Method: Phase 2

Research Agent

- Web Search
 - 초기 가설 관련 최신 정보 검색
- Information Validation
 - 최신·관련성 높은 결과만 필터링/종합

----- HOTL system executed -----
- Hypotheses Refinement
 - 검증된 정보, 초기 가설 기반 정제
 - 단계별 구현 지침, 코딩 agent가 참고할 Pseudo-code 작성

----- HOTL system executed -----

Debate Agents

- Pro vs. Con Agents Debate
 - 최종 가설 목록 선정을 위한 찬반 토론
 - 매 round 이후 self-reflection을 통한 합의 시도
- Judge Agent
 - Max round까지 Pro-Con agents 간 합의 불발 시 호출
 - 이전 토론 로그 기반 추론 및 최종 판결

Method: Phase 3

Project Leader

- Dynamic agent planning
 - 주어진 Task에 따라 n 개의 model agents의 Spec.을 정의

----- HOTL system executed -----

Dynamically Generated Agents

- 주어진 Task에 따라 Dynamic하게 생성되는 Model Agents
 - Agent Factory가 동적 생성한 agents로 dynamic agent pool 구성
 - 각각 부여받은 작업 수행
- Eval/Debug Agent
 - 생성된 코드 실행 및 디버깅 후 평가 진행
- Performance Check
 - 목표 성능 달성 여부 검사 및 최고 성능 가설 선택

Method: Phase 4

Ablation Agent

- Phase 3 반환 코드에 대한 ablation study 수행

----- HOTL system executed -----

- Class 단위 ablation
 - Class별 전체적인 성능에 미치는 영향력 평가
- Ablation summary
 - Class별 영향도 순위 요약

Refinement Agent

- Ablation summary 기반 영향도 상위 k 개 target classes 선정
- Target classes에 대한 iterative refinement
 - k 개의 class 순회
 - Class 별로 r 번의 iterative refinement 진행

Method: Final Result Return

Project Leader

- Comprehensive report generation
 - User input 분석
 - 동적 agent 코드 생성 과정 정리
 - 최종 코드
 - 최종 평가 결과

Experiments (Result)

본 Agentic AI 시스템이 생성한 모델의 성능 : RMSE 기준 약 **“4.27733”** (private 점수 기준)

	제목	제출 일시	public점수 private점수	제출선택
1320513	predictions.zip real just try... gg edit	2025-09-12 07:00:34	4.2837360527 4.2773356485	☐

2022 Samsung AI Challenge (3D Metrology) Private 리더보드 상에서 **상위 14등의 성능**을 보임.

- 생성된 코드는 본 System과 Human-on-the-loop를 통해 생성되었으며 다음 슬라이드에서 설명

Experiments (🔍 HOTL 적용 단계별 정리)

Phase 1: 프로젝트 분석 및 계획 (Project Leader)

✅ phase1_project_analysis 이후: 프로젝트 분석 결과가 목표와 일치하는지 인간 검토자의 확인

```

🔄 === Human-on-the-Loop: phase1_project_analysis ===
📁 상황 : 프로젝트 및 코드 분석이 완료되었습니다. 분석 결과를 검토해 주세요.
🇰🇷 이전 결과 :
-----
[가설 1] 프로젝트 분석 :
### **AI 모델 개발 프로젝트 계획서 : SEM 이미지 기반 Depth Map 예측**

**문서 버전 : ** 1.0
**작성자 : ** AI 모델 개발 프로젝트 리더

---

### **1. 프로젝트 개요 (Project Overview)**

본 프로젝트의 최종 목표는 **2D 주사전자현미경 (SEM) 이미지로부터 3D 깊이 정보가 담긴 Depth Map을 예측**하는 AI 모델을 개발하는 것입니다.

핵심 과제는 시뮬레이션으로 생성된 데이터 ($SEM^S$, $Depth^S$)와 실제 장비로 촬영된 데이터 ($SEM^T$) 간의 *...

[가설 1] 코드 분석 :
## 기술 분석 보고서 : SEM 이미지 기반 Depth 예측 모델 구현 분석

본 보고서는 제공된 참조 코드 (`code/1`, `code/2`)를 심층 분석하여 기존 AI/ML 모델 구현의 구조, 강점, 약점을 파악하고, 프로젝트 목표 달
  
```

선택하세요 :

1. 계속 진행 (Continue)
2. 수정 후 재시도 (Retry)
3. 중단 (Abort)

입력 (1/2/3): █

Experiments (🔍 HOTL 적용 단계별 정리)

Phase 2: 연구 및 가설 개선 (Research)

✅ phase2_research_and_hypothesis_instruction 이후 - 리서치 결과 및 실행계획 검토

```

=== Human-on-the-Loop: phase2_research_and_hypothesis_instruction ===
상황 : 외부 리서치 및 가설 개선이 완료되었습니다. 리서치 결과와 실행계획을 검토해 주세요.
이전 결과 :
-----
[가설 1] 리서치 결과 :
```json
[
 {
 "id": "arxiv_2401.07182_diffmed",
 "url": "https://arxiv.org/abs/2401.07182",
 "title": "[2401.07182] Unsupervised Domain Adaptation for Medical Image-to-Image Trans
[가설 2] 리서치 결과 :
```json
[
  {
    "id": "3",
    "url": "https://github.com/lhoyer/HRDA",
    "title": "lhoyer/HRDA: Source code for 'HRDA: Context-Aware High-Resolution Domain-Adaptive Semantic Segmentation' (ECCV 2...

[가설 1] 실행 계획 :
```json
[
 {
 "hypothesis": {
 "summary": "U-Net 기반 End-to-End 회귀 및 Self-Correcting Pseudo-Labeling을 통한 성능 극대화",
 "detailed plan": "이 가설은 'code analysis'에서 가장 유망하다고 평가된 'code/2'의 End-to-

```

선택하세요 :

1. 계속 진행 (Continue)
2. 수정 후 재시도 (Retry)
3. 중단 (Abort)

입력 (1/2/3): █

# Experiments (🔍 HOTL 적용 단계별 정리)

## Phase 2: 연구 및 가설 개선 (Research)

✅ phase2\_debate 이후 - 결정된 최종 가설 검토

🔄 === Human-on-the-Loop: phase2\_debate ===

📁 상황 : 가설 토론이 완료되고 최종 가설이 선정되었습니다. 선정된 가설을 검토해 주세요.

📊 이전 결과 :

토론 결과 1개 가설이 선정되었습니다 :

[가설 2] 1. 작업 정의 (Task Definition)

최종 목표

시뮬레이션으로 생성된 2D 주사전자현미경 (SEM) 이미지와 실제 촬영된 SEM 이미지 간의 차이 (Domain Gap)를 극복하고, 최종적으로 테스트를 정확하게 예측하는 모델을 개발합니다.

데이터셋 특성 및 핵심 과제

\* 시뮬레이션 데 ...

선택하세요 :

1. 계속 진행 (Continue)
2. 수정 후 재시도 (Retry)
3. 중단 (Abort)

입력 (1/2/3): █

# Experiments (🔍 HOTL 적용 단계별 정리)

## Phase 3: 모델 개발 (Model Development)

✅ phase3\_agent\_specification\_generation - 동적으로 생성된 에이전트 스펙 검토

✅ 프로젝트 리더가 2개의 동적 에이전트 스펙을 생성했습니다.

1. Augmentation\_Pipeline\_Developer - Albumentations 기반 물리적 증강 전문가
2. UNet\_Depth\_Modeler\_Agent - U-Net 기반 깊이 예측 모델 개발 전문가

🔄 === Human-on-the-Loop: phase3\_agent\_specification\_review ===

📁 상황 : 동적 에이전트 개발을 시작하기 전에 에이전트 스펙을 검토해 주세요.

🇮🇹 이전 결과 :

-----  
2개의 동적 에이전트 스펙이 준비되었습니다 :

### \*\*1. Augmentation\_Pipeline\_Developer\*\*

- 역할 : Albumentations 기반 물리적 증강 전문가
- 목표 : 실제 SEM 이미지의 물리적 특성 (노이즈, 아티팩트 등)을 모사하는 고성능 데이터 증강 파이프라인을 개발하여, 후속 모델
- 태스크 : 물리 기반 데이터 증강 파이프라인 스크립트 개발
- 설명 : 선정된 가설과 연구 자료 9번 (Albumentations)을 기반으로, `Simulator\_SEM` 데이터에 적용할 학습용 증강 파이프라인을
- 예상 출력 : 독립적으로 실행 가능한 단일 Python 스크립트 `augmentations.py`. 이 스크립트는 `get\_train\_augmentations()`라

### \*\*2. UNet\_Depth\_Modeler\_Agent\*\*

- 역할 : U-Net 기반 깊이 예측 모델 개발 전문가
- 목표 : `convolutional\_autoencoder.py`의 우수한 구조를 기반으로, 모델 아키텍처를 U-Net으로 개선하고 복합 손실 함수 (L1+SS
- 태스크 : U-Net 모델 아키텍처 및 학습 스크립트 개발
- 설명 : 제공된 `convolutional\_autoencoder.py`를 참조 코드로 삼아 개선 작업을 수행합니다. 첫째, 기존 `NewModel` 클래스를
- 예상 출력 : 완전한 기능을 갖춘 단일 Python 스크립트 `train\_depth\_model.py`. 이 스크립트는 커맨드 라인 인자를 통해 데이터

선택하세요 :

1. 계속 진행 (Continue)
2. 수정 후 재시도 (Retry)
3. 중단 (Abort)

입력 (1/2/3): █

# Experiments (🔍 HOTL 적용 단계별 정리)

## Phase 3: 모델 개발 (Model Development)

✅ phase3\_integration\_development 이후 - 통합 실행 결과 검토

```

📁 코드 저장됨 : generated_code/unet_depth_modeler.py
✅ UNet_Depth_Modeler_Agent 개발 완료

🎉 총 2개 에이전트의 모델 개발이 완료되었습니다!

🔄 === Human-on-the-Loop: phase3_dynamic_agent_development ===
📁 상황 : 동적 에이전트 개발이 완료되었습니다. 생성된 에이전트와 코드를 검토해 주세요.
🇮🇹 이전 결과 :

2개의 동적 에이전트가 개발되었습니다 :

- Augmentation_Pipeline_Developer: ✅ 코드 생성 완료
- UNet_Depth_Modeler_Agent: ✅ 코드 생성 완료

개발된 에이전트 스펙 :
- Augmentation_Pipeline_Developer: 선정된 가설과 연구 자료 9번 (Albumentations)을 기반으로, `Simulator_SEM` 데이터에 적용할 학습용
 성합 ...
- UNet_Depth_Modeler_Agent: 제공된 `convolutional_autoencoder.py`를 참조 코드로 삼아 개선 작업을 수행합니다. 첫째, 기존 `NewMode
 l`

선택하세요 :
1. 계속 진행 (Continue)
2. 수정 후 재시도 (Retry)
3. 중단 (Abort)
입력 (1/2/3): █

```

# Experiments (🔍 HOTL 적용 단계별 정리)

## Phase 4: 어블레이션 리서치 (Ablation Research)

✅ check\_ablation\_plan - 어블레이션 계획이 적절하고 안전한지 인간 검토자의 확인

=== Phase 4: Ablation Research ===

🔍 어블레이션 계획 수립 중 ...

✅ 어블레이션 계획 수립 완료 .

🔄 === Human-on-the-Loop: phase4\_ablation\_plan\_verification ===

📋 상황 : Ablation Crew가 생성한 어블레이션 실행 계획입니다 . 계획이 적절하고 안전한지 검토 후 진행 여부를 결정해 주세요 .

📊 이전 결과 :

-----  
**\*\*Ablation Study Plan\*\***

1. **\*\*Target Component Analysis:\*\***

- The `VisionTransformer` module in `vision\_model.py` is identified as the primary component for feature extraction

# Experiments (Logs 분석)

## 1. 에이전트가 정리한 프로젝트 내용

### 프로젝트 개요

**프로젝트명:** 전자현미경(SEM) 이미지로부터 3D Depth Map을 예측하는 AI 알고리즘 개발

**최종 목표:** 실제 장비로 촬영된 2D SEM 이미지(Test\_SEM)로부터 3D 깊이 정보를 담은 Depth Map을 정확히 예측하는 모델 파이프라인 구축

**핵심 과제:** 시뮬레이션 데이터와 실제 데이터 간의 '도메인 갭(Domain Gap)'을 극복하는 비지도 도메인 적응(Unsupervised Domain Adaptation, UDA) 문제 해결

**목표 성능:** RMSE 3.8 이하 달성

### 구현 전략: 3단계 분리형 파이프라인

초기 가설을 채택하여, 도메인 적응과 예측 단계를 명확히 분리하는 3단계 파이프라인을 구축합니다.

- Case 분류 (Classification): 입력된 SEM 이미지를 배경 값에 따라 4개의 Case로 사전 분류하여 문제의 복잡도를 낮춥니다.
- 도메인 적응 (Domain Adaptation): CycleGAN을 활용하여 시뮬레이션 이미지를 실제 이미지 스타일로 변환합니다.
- Depth Map 추론 (Inference): k-Nearest Neighbors(KNN) 방식을 사용하여, 테스트 이미지와 가장 유사한 변환 이미지를 찾고, 이들의 원본 Depth Map을 평균내어 최종 결과를 예측합니다.

# Experiments (Logs 분석)

## 2. 리서치 데이터

비지도 도메인 적응(UDA)을 이용한 깊이 추정(Depth Estimation) 관련 최신 연구 자료들을 수집했습니다. 주요 내용은 다음과 같습니다.

- A Simple yet Effective Test-Time Adaptation for Zero-Shot Monocular Metric Depth Estimation: 미세조정 없이도 기존 모델의 일반화 성능을 유지하면서 깊이를 정확하게 추정하는 방법을 제안합니다.
- One Look is Enough: 고해상도 이미지에서 발생하는 깊이 추정의 불연속성 문제를 해결하고, 패치(Patch) 기반 처리 방식을 개선하여 효율성을 높이는 프레임워크를 제시합니다.
- Self-Supervised Learning based Depth Estimation from Monocular Images: Monodepth2와 같은 모델을 기반으로, 별도의 카메라 정보 없이도 깊이 추정 모델을 학습하고 성능을 개선하는 방법을 탐구합니다.
- Vanishing Depth: 사전 학습된 이미지 인코더를 깊이 추정에 맞게 조정하는 어댑터(Adapter) 방식을 제안하여, 효율적으로 모델을 개발하는 방법을 제시합니다.
- Synthetic-to-Real Self-supervised Robust Depth Estimation: 동작(Motion) 및 구조(Structure) 정보를 활용하여 시뮬레이션 데이터와 실제 데이터 간의 지식 격차를 해소하는 방법을 제안합니다. 이는 실제 SEM 이미지의 특성을 모델에 학습시키는 데 유용한 아이디어가 될 수 있습니다.

...

# Experiments (Logs 분석)

## 3. 토론 내용

두 개의 초기 가설에 대해 찬반 토론이 진행되었습니다.  
최종적으로는 안정성과 예측 가능성을 중시하여 가설 1을 채택하기로 결론 내렸습니다.

이유로는 성능 잠재력이 조금 낮더라도 실패 위험이 적고, 문제 발생 시 대처하기 용이한 가설 1(분리형 파이프라인)을 채택하여 프로젝트를 진행하기로 결정한 것입니다.

# Experiments (Logs 분석)

## 가설 1: 분리형 파이프라인 (CycleGAN + KNN) - (최종 채택 )

이 접근법은 '도메인 적응'과 '깊이 예측'이라는 두 가지 어려운 문제를 명확히 분리하여 단계적으로 해결하자는 아이디어입니다.

### 찬성 측 핵심 주장 (안정성 및 신뢰성)

**문제의 단순화:** 복잡한 'End-to-End' 모델 하나를 만드는 대신, '이미지 변환'과 '유사도 기반 예측'이라는 두 개의 더 작고 검증된 문제로 나누어 접근하므로 개발 과정의 불확실성이 크게 줄어듭니다.

**디버깅 용이성:** 파이프라인이 단계별로 나뉘어 있어, 만약 최종 결과가 좋지 않을 경우 어느 단계(이미지 변환 문제인지, 예측 문제인지)에서 문제가 발생했는지 명확하게 파악하고 수정하기 쉽습니다.

**예측의 강건함(Robustness):** 최종 예측을 회귀(Regression) 모델이 아닌 k-최근접 이웃(KNN) 방식으로 수행합니다. 이는 훈련 데이터에 없던 특이한 이미지가 들어와도 모델이 완전히 잘못된 값을 내놓는 '오버피팅'의 위험 없이, 가장 유사한 기존 데이터 기반으로 안정적인 예측을 할 수 있다는 큰 장점이 있습니다.

### 반대 측 핵심 주장 (정보 손실 및 비효율성)

**정보 손실 가능성:** CycleGAN으로 시뮬레이션 이미지를 실제 이미지 스타일로 변환하는 과정에서, 깊이 예측에 중요했을 미세한 정보들이 손실될 수 있다는 우려가 제기되었습니다.

**최적화의 한계:** 각 단계가 따로 최적화되므로, 파이프라인 전체가 '깊이 예측'이라는 최종 목표에 대해 100% 최적화되었다고 보기 어렵습니다. (일명 '프랑켄슈타인 모델' 문제)

**추론 시간:** KNN 방식은 예측 시마다 테스트 이미지를 모든 훈련 데이터와 비교해야 하므로, 데이터가 많아질수록 추론(Inference) 속도가 매우 느려질 수 있습니다.

# Experiments (Logs 분석)

## 가설 2: 통합된 End-to-End 모델

이 접근법은 입력(시뮬레이션 이미지)부터 출력(Depth Map)까지 전체 과정을 하나의 거대한 신경망으로 묶어 한 번에 학습시키자는 아이디어입니다.

### 찬성 측 핵심 주장 (최대 성능 및 효율성)

**성능 잠재력:** 모델의 모든 부분이 '깊이 예측'이라는 단 하나의 목표를 위해 동시에 최적화되므로, 성공적으로 학습된다면 가설 1보다 더 높은 정확도를 달성할 잠재력이 있습니다.

**구조의 단순함:** 중간 과정 없이 하나의 모델만 관리하면 되므로, 배포 및 운영이 더 간편할 수 있습니다.

**빠른 추론 속도:** 학습이 완료된 후에는 이미지를 입력하면 곧바로 결과가 나오므로, KNN 방식보다 추론 속도가 훨씬 빠릅니다.

### 반대 측 핵심 주장 (높은 불안정성 및 리스크)

**높은 학습 난이도:** 도메인 적응과 깊이 예측이라는 두 가지 어려운 태스크를 동시에 학습시키는 것은 매우 불안정하며, 학습이 실패할 위험이 큼니다.

**'블랙박스' 문제:** 모델 내부에서 어떤 일이 일어나는지 해석하기가 매우 어렵습니다. 문제가 발생했을 때 원인을 찾아 해결하기가 거의 불가능에 가깝습니다.

**'지름길 학습(Shortcut Learning)' 위험:** 모델이 깊이를 이해하는 대신, 두 도메인 이미지 간의 피상적인 통계적 특징(예: 특정 색감이나 노이즈 패턴)만을 학습하여 우연히 정답을 맞히는 방식으로 학습될 가능성이 있습니다. 이 경우 새로운 데이터에 대해서는 성능이 급격히 저하됩니다.

# Future Works

01

Web interface  
for Human-on-the-loop

현재는 CLI(Command Line Interface) 환경이나, ChatOps 형식으로 Web interface를 구현한다면 더 높은 UX(User Experience)를 달성할 수 있음.

02

Docker Container  
for CodeInterpreterTool

본 시스템은 multi-agent이므로 Docker 컨테이너 환경을 도입하여, 에이전트 내의 environment isolation을 통해 시스템의 안정성을 증대할 수 있다.

03

HPO Agent 추가

Phase3/4 이후 구현된 AI 모델의 성능 극대화를 위해, **Hyperparameter Optimization**을 진행해주는 **Agent** 추가

Search space, search algorithm등을 프로젝트 리더 에이전트가 결정하는 원리

특히 이번 task는 단순 seed에 따라서 성능이 0.8까지도 차이가 나는 것을 확인!

# References

- 1 Romero, M. L., & Suyama, R. (2025). Agentic AI for intent-based industrial automation. arXiv preprint arXiv:2506.04980.
- 2 SAMSUNG SDS - AI 시스템을 강화하는 휴먼인더루프(HUMAN IN THE LOOP)  
[https://www.samsungsd.com/kr/insights/human\\_in\\_the\\_loop.html](https://www.samsungsd.com/kr/insights/human_in_the_loop.html)
- 3 Yoon, J., & Nam, J. (2025). MLE-STAR: A state-of-the-art machine learning engineering agent. Google Cloud Technical Report.
- 4 Trirat, P., Jeong, W., & Hwang, S. J. (2025). AutoML-Agent: A multi-agent LLM framework for full-pipeline AutoML. In Proceedings of the 42nd International Conference on Machine Learning.

End of PPT